Encodage des textes patrimoniaux Le manuscrit (1) Transcription

Lou Burnard





Objectifs

- découvrir les balises spécifiques pour l'encodage de transcriptions des manuscrits
- lettres, abbreviations, ratures, choice, etc,
- faire le point sur l'édition génétique
- facsimilé, liens image/transcription





La transcription des sources primaires

Quelles caractéristiques d'une source primaire pourrait-on vouloir exprimer dans un travail de transcription ?

- la manière dont le texte est inscrit sur la page
- l'orthographe
- le rendu formel original (s'il a une importance)
- la ponctuation originale
- les abréviations
- les ajouts et suppressions
- les erreurs et omissions
- eventuellement, les illustrations, dessins ou graphiques illustrant le texte
- la structure logique du texte
- peut-être d'autres choses, selon le point de vue qu'on adopte et les objectifs du projet...





Objectifs d'un projet de transcription

- mettre à disposition du plus grand nombre de chercheurs -- ou curieux -- des sources primaires
- ... en les rendant compréhensibles à un public moderne
- établir un texte definitif à partir de plusieurs témoins, completer la transcription avec un stemma ou tableau de la tradition, et des notes d'apparat critique
- mettre en place un paratexte fournissant des notes explicatives ou historiques pour identifier un lieu, une personne, etc.

Dans tous les cas, la transcription devrait s'appuyer sur des règles éditoriales qui seront explicitées, et qui seront elles-mêmes fondées sur des recommandations admises dans la discipline scientifique concernée.





Les principaux éléments TEI utiles pour la transcription

```
Définis dans le module 'core': <abbr>, <add>, <choice>, <corr>,
             <del>, <expan>, <gap>, <sic>
Définis dans le module 'transcr': <addSpan>, <am>, <damage>,
             <damageSpan>, <delSpan>, <ex>, <facsimile>, <fw>,
             <handNotes>, <handShift>, <restore><space>,
             <subst>, <supplied>, <surface>, <zone>
Définis dans le module 'textcrit': <app>, <lacunaEnd>,
             <lacunaStart>, <lem>, <listWit>, <rdg>, <rdgGrp>,
             <variantEncoding>, <wit>, <witDetail>, <witEnd>,
             <witStart>, <witness>
```





Structure logique et mise en page du texte

Par *structure*, on entend l'organisation du texte en parties constituantes, par *mise* en page la manière dont le texte est inscrit, réparti, sur le support.

Le texte étudié et l'objet physique sur lequel ce texte est inscrit ont des structures hiérarchiques distinctes, qu'il faut toutes les deux encoder dans l'idéal...

... ce qui provoque des problemes de chevauchement.

Pour la structure logique, les manuscrits et les imprimes ont tous les deux les memes possibilites.





Encodage de la structure physique

Pour exprimer la manière dont le texte est inscrit sur le support physique, des éléments vides de type 'milestone' (borne) sont disponibles, <gb/>, <pb/>, <cb/>, et <lb/>, qui correspondent respectivement à la désignation des debuts de cahier ("gathering"), page, colonne et ligne.

Comme tout élément, on peut numéroter et identifier ceux-ci au moyen des attributs @n et @xml:id pour etablir un systeme de referencement.





Encodage de la structure physique : exemple

a ferry fortungame de -Broant Popf propos an more a buy folm a semi de zemide conte coarme por po? inquate Conts four. Que le pens de grinza cinese Lown Le mare Targent L'esp fuf cofinec ca faburation DEE 1= (fore a Dipo Denter In Brist grame froys quarty it fing qui ball buza squiese ho grame dargent (troy, a

<!-- ... -->

< pb n = "5r" /> < fw > 5 < / fw >

<lb/><expan>et</expan> demy trebuchans de

<lb/>soixante sept pieces au marc

<lb/>a ung felin <expan>et</expan> demy de
remede

<lb/>Cours chacune piece

<expan>pour</expan>

<lb/><expan>cinquante</expan> soubz

<expan>tournois

<lb/>Sur le pris de quinze livres

<lb/><expan>tournois</expan> le

marc dargent le roy

<lb/>fust <expan>continuee</expan> la

<expan>fabricacion</expan>

<lb/>des testons a dix deniers

<lb/>dix huict grains troys quartz

<lb/>de fin qui <expan>valent</expan> unze
deniers

<lb/>six grains dargent le roy<pc>,</pc> a





Titres courants, réclames, etc.

<fw> L'élément <fw> (forme work, ou élément de mise en page) permet d'encoder un titre courant (en haut ou en bas de la page), une réclame ou une autre information comparable, qui apparaît sur la page courante.

```
<fw place="top-centre" type="head">Poëms.</fw>
<fw place="top-right" type="pageno">29</fw>
<fw place="bot-centre" type="sig">E3</fw>
<fw place="bot-right" type="catch">TEMPLE</fw>
```

Nota: cet élément sert à encoder les references déjà existant dans le manuscrit.





Les abréviations

Les abréviations sont très caractéristiques des manuscrits de toutes sortes. On distingue plusieurs types d'abréviations :

Abréviations par suspension la ou les premières lettres du mot sont écrites, suivies en général d'un point ou d'une autre marque : par exemple 'e.g.' pour 'exempli gratia'.

Abréviations par contraction les première(s) et dernière(s) lettres du mot sont écrites, accompagnées le plus souvent d'un signe abréviatif tel que trait suscrit, ou, plus rarement, un point : par exemple 'ā' pour 'an', 'M'. pour 'Monsieur' etc.

"Brévigraphes" ce sont des symboles spécifiques, tels que la note tironienne (⁊ ☒) utilisée à la place de la conjonction de coordination 'et', la lettre p barrée (ᵱ ☒), souvent utilisée à la place de la syllabe 'per'.



La plupart des symboles dont on a besoin sont définies par Unicode,

Les abréviations et leur résolution

Une abréviation peut être restituée de deux manières :

- on peut choisir de consigner l'abréviation non développée, en la transcrivant simplement tel quel: par exemple, 'po suivi de r superieure' ou un 'a avec macron'
- on peut aussi interpréter ou développer l'abréviation, en remplaçant la ou les lettres par leur signification : par exemple, 'pour', 'an'

La TEI permet de fournir à la fois les formes abrégées et développées des abréviations.





Encoder les abréviations

La TEI propose deux niveaux d'encodage :

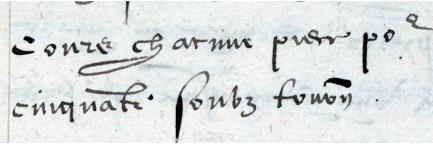
- la totalité d'un mot abrégé et la totalité de sa forme développée peuvent être encodés au moyen des éléments <abbr> et <expan>
- le symbole utilisé pour indiquer la suppression d'une ou plusieurs lettres peut etre encodé par l'élément <am>; les lettres substituées à ce symbole lorsqu'on résoud l'abréviation par l'élément <ex>

lci aussi on peut utiliser les deux niveaux conjointement.





Un exemple



Selon la stratégie éditoriale, on peut signaler simplement qu'il y avait des formes abrégés qu'on a rétablis:

```
<lb/>Cours chacune piece <expan>pour</expan></b/><expan>cinquante</expan> soubz<expan>tournois</expan><pc>.</pc>
```





Encodage des formes graphiques des abbreviations

Mais, en effet, 'pour' a ete ecrit 'po' suivi d'une lettre 'r' suscrite; 'cinquante' comme 'cinquāte' avec un macron sur le 'a' pour signaler la nasalisation.

On pourrait donc encoder ces mots de l'une ou l'autre des manières ci-après :

```
>
 <abbr>po&#xFFFD;</abbr> .... <abbr>cinquāte</abbr>
... ou:
 po<am>&#xFFFD;</am> ... ou po<ex>u</ex>r 
>
 <abbr>po<am>&#xFFFD;</am>
 </abbr> ou
<expan>po<ex>u</ex>r</expan>
```



Utilisation de <choice>

Toutes ces paires d'éléments peuvent être englobées dans un élément <choice> (choix) :

```
 po<choice>
    <am>&#FFFD;</am>
    <ex>ur</ex>
    </choice>
```

```
<choice>
<abbr>po<am>&#xFFFD;</am>
</abbr>
<expan>po<ex>u</ex>r</expan>
</choice>
```





Catégoriser les abréviations

L'attribut @type de l'élément <abbr> sert a catégoriser les abréviations, qu'il s'agisse de préparer une analyse statistique ou de restituer ces abréviations de manière différente selon leur type.

Par exemple, on peut vouloir afficher le développement des abréviations par suspension entre crochets, d'autres types en italique ou entre parenthèses etc.

```
<choice>
<abbr type="brevigraphe">po<am>&#xFFFD;</am>
</abbr>
<expan>po<ex>u</ex>r</expan>
</choice>
```

L'inscription encodée ci-dessus peut être affichée comme suit : 'po(u)r'

Comme ailleurs, les attributs @resp et @cert sont disponibles pour indiquer l'agence responsable de la forme développée, et le degré de certitude de cette interprétation.





Corrections

L'élément <sic> peut être utilisé pour indiquer que la leçon donnée par le manuscrit est erronée ou n'a pas de sens, tandis que l'élément <corr> sert à fournir ce qui est la leçon correcte selon l'opinion de l'éditeur :

```
<sic>relea</sic>
<corr>relicta</corr>
```

Les deux éléments peuvent être associés au sein d'un élément <choice> :

```
<choice>
  <sic>relea</sic>
  <corr>relicta</corr>
</choice>
```





Normalisation

Les sources primaires utilisent rarement l'orthographe moderne. Pour la recherche ou pour d'autres raisons liées aux traitements informatiques prévus, la graphie moderne peut s'avérer utile dans une transcription. L'élément <reg> (régularisation) est disponible pour encoder une forme normalisée, tandis que l'élément <orig> (forme originale) contient la graphie d'origine non normalisée. On peut si on le souhaite regrouper ces éléments de contenu alternatif en utilisant l'élément <choice>.





Normalisation (exemple)

```
droßnirt grame froyre quartz
```

```
<ld><lb/>dix <choice>
    <orig>huict</orig>
    </choice>
    grains
    <choice>
    <orig>troys quartz</orig>
    <reg>trois-quart</reg>
</choice>
</orig>
```

Dans ce cas, il existe aussi la possibilité d'une régularisation sémantique:



Ajouts, suppressions et substitutions

Les changements opérés sur le texte inscrit, qu'ils soient faits par le scripteur ou ultérieurement par une autre main, peuvent être encodés au moyen des éléments <add> (ajout) ou (suppression).

- <add> contient des lettres, des mots ou des phrases insérées dans le texte par un auteur, un copiste, un annotateur ou un correcteur.
- contient une lettre, un mot ou un passage supprimé, marqué comme supprimé, sinon indiqué comme superflu ou erroné dans le texte par un auteur, un copiste, un annotateur ou un correcteur.

Lorsque les ajouts et suppressions sont considérés comme une s seule opération de *substitution*, les éléments <add> et peuvent être groupés au moyen de l'élément <subst> (substitution).





<add> et : exemples

oak non, vue denie

```
<add hand="#PDN" place="margin-left">
  <subst>
   <del>Oui</del>
   <add>Non, une demie</add>
   </subst>
</add>
```





Dommages matériels et difficultés de lecture

Utiliser l'élément <unclear> si le texte est devenu partiellement illisible, par exemple par suite de suppression ou dommages matériels, de sorte qu'il peut être lu mais sans certitude.

Utiliser l'attribut @reason pour déclarer la cause de l'incertitude dans la transcription et l'attribut @cert pour donner une idée de la confiance que l'on peut avoir dans la transcription.

```
<add hand="#EPR" place="inspace">Envoyez-moi une épreuve
<unclear cert="medium">W</unclear>
<gap reason="non-dechiffrable"/>
</add>
```

L'élément <damage> est à utiliser pour indiquer les zones du document sur lesquelles des dommages matériels affectent le texte, mais où l'on peut lire au moins une partie du texte avec certitude. Les attributs @agent et @extent précisent respectivement la cause et l'étendue des dommages.



<addSpan> et <delSpan>

Ces deux éléments délimitent une section de texte au moyen de pointeurs plutôt qu'en encadrant la section de texte. Ils sont utiles si un ajout ou une suppression chevauche une autre portion de texte. L'attribut @spanTo indique où se situe la fin d'une portion de texte commençant par l'élément qui porte l'attribut.

```
<delSpan spanTo="#id4"/>
<!-- texte supprime -->
<anchor xml:id="id4"/>
```





Substitutions

L'élément <subst> (substitution) associe une ou plusieurs suppressions avec un ou plusieurs ajouts lorsque cette combinaison peut être considérée comme une seule intervention sur le texte. Exemples :

- un mot ou une lettre écrit par-dessus un(e) autre
- un mot ou une lettre supprimé, remplacé par un(e) autre écrit au-dessus par la même main lors de la rédaction du texte
- un mot ou une lettre supprimé, remplacé par une main différente à un autre moment

<subst> ne suffit pas pour l'encodage des cas plus complexes, par exemple une longue série de substitutions dont l'ordre peut être incertain, ainsi que le choix de la leçon à préférer.





Exemple (simple): <subst>
And towards our distant rest began to rudge,

And towards our distant rest began to rudge,

Helping the worst amongst us, who'd no boots all

Helping the worst amongst us, who'd no boots all

But limped on, blood-shod. All went lame; hatf blind;

But limped on, blood-shod. All went lame; hatf blind;

Drunk with Jatique; deaf even to the hoots

Of tires, outstripped fif five-nines that dropped behind.

```
<l>And towards our distant rest began to trudge,</l>
<1>
 <subst>
   <del>Helping the worst amongst us</del>
   <add>Dragging the worst amongt us</add>
 </subst>, who'd no boots
</1>
<l>But limped on, blood-shod, All went lame: <subst>
   <del>half-</del>
   <add>all</add>
 </subst> blind:</l>
<l>>Drunk with fatique : deaf even to the hoots</l>
<l>Of tired, outstripped <del>fif</del> five-nines that dropped behind.</l>
```





Restitutions de portions de texte dans la transcription

Lorsqu'un mot est restitué par l'éditeur, on peut utiliser l'élément <supplied>.

Il est d'usage de distinguer le texte devenu aujourd'hui illisible ou disparu par suite de dommages matériels, mais réputé présent à l'origine dans le document manuscrit (qui est imprimé entre crochets carrés selon certaines conventions éditoriales), et le texte réputé omis par inadvertance par le scripteur (imprimé alors le plus souvent entre crochets pointus). On fera cette distinction dans le fichier TEI en se servant de l'attribut @reason:

```
...Dragging the worst among<supplied reason="omitted">s</supplied>t us...
```





Métadonnées du texte restitué

les attributs @resp and @cert peuvent être employés ici comme ailleurs. Un attribut @source est également disponible pour indiquer qu'on se fie à un autre témoin du texte pour proposer une restitution :

Source de l'exemple : édition critique du cartulaire blanc de Saint-Denis, chapitre de Beaurain, acte 2.





L'élément < gap >

Lorsque le texte manquant ne peut être rétabli, l'élément à utiliser est <gap>. à l'aide de l'attribut @reason, on pourra donner la raison de cette lacune dans la transcription, et les attributs @extent et @unitdonneront la taille présumée du segment manquant.

```
<gap reason="damage" extent="7" unit="chars"/>
```





Autres utilisations de l'élément <gap>

L'élément <gap> peut aussi être utilisé lorsque le segment de texte, bien présent et lisible, est omis dans la transcription, que ce soit pour des raisons éditoriales ou parce qu'on a sélectionné les sections de texte à transcrire.

```
<div rend="slide">
   <head>Lectio x.</head>
    Hic itaque paterfamilias ad excolendam
<gap extent="20" unit="words" reason="not transcribed" resp="#DC"/>
congregare
   non desistit. 
</div>
```





<handShift>

<handShift> (reprise de main) marque le début d'une section du texte écrite par une nouvelle main ou le début d'une nouvelle séance d'écriture.

```
<lr><l>When wolde the cat dwelle in his ynne</l>
<handShift medium="greenish-ink"/>
<l>And if the cattes skynne be slyk <handShift medium="black-ink"/>
and gaye</l>
```

```
<handShift new="#h1" resp="#das"/>
... and that good Order Decency and regular worship may be once
more introduced and Established in this Parish according to the
Rules and Ceremonies of the Church of England and as under a good
Consciencious and sober Curate there would and ought to be
<handShift new="#h2" resp="#das"/> and for that purpose the
parishioners pray
```





definition des mains

```
<handNotes>
  <handNote xml:id="h1" script="copperplate">Carefully written with
    regular descenders</handNote>
  <handNote xml:id="h2" medium="pencil">Unschooled scrawl</handNote>
  </handNotes></handNotes></handNotes></handNotes>
```





Annulation des suppressions

L'élément <restore> indique une intervention qui conduit au retour du texte à un état antérieur, par annulation d'une opération ou instruction de l'éditeur ou de l'auteur.

Si dans la ligne 'For I hate this my body' du poème de D. H. Lawrence *Eloi, Eloi, Lama Sabachthani?*, le mot 'my' a d'abord été supprimé puis restauré en écrivant 'stet' dans la marge, on pourra encoder ce processus ainsi:

```
[...] For I hate this <restore hand="#dhl" type="marginalStetNote">
        <del>my</del>
        </restore> body [...]
```

... mais cela ne suffit pas pour l'édition génétique





L'édition génétique

Un travail en cours, mais avec des résultats déjà apparents.

- quelques éléments supplémentaires pour les transcriptions <mod>, <modSpan>, <metaMark>, <used>, <undo>, <redo>,
 <rewrite>, <transposeGrp>, <transpose>
- des mécanismes pour encoder les étapes d'écriture, par exemple un attribut @stage qui associe n'importe quel élément de la transcription avec une étape identifiée dans l'évolution du document
- une structuration parallèle du document vu comme object physique, composé des surfaces, zones, et lignes

http://www.tei-c.org/Activities/Council/Working/tcw19.html ... à commenter!





L'édition en fac-similé

- Une édition numérique peut etre composée uniquement de pages images, associée avec des metadonnées.
- On peut également identifier des zones d'interet dans les images
- Et encoder des liens entre ceux-ci et les parties d'une transcription





Une solution tres simple

Inconvenients de la solution simplissime...

- doesnt scale well if more complex linking is needed
- complicates and obscures digital image info
- requires something else (typically mets)





Une solution meilleure

Rassemblement des donnees

```
<facsimile
    xml:base="http://mylibrary.wibble.fr/blah/blah/blah">
    <graphic url="page1.png"/>
    <graphic url="page2.png"/>
    <graphic url="page3.png"/>
    <graphic url="page4.png"/>
    <facsimile>
```





Maintenant, si on a des versions alternatives?

On se sert de <surface> pour regrouper les images équivalentes:

```
<facsimile>
<graphic url="page1.png"/>
<surface>
<graphic url="page2-highRes.png"/>
<graphic url="page2-lowRes.png"/>
</surface>
<graphic url="page3.png"/>
<graphic url="page4.png"/>
<ffacsimile>
```





Liaison image/ transcription

```
<facsimile>
<graphic xml:id="page1" url="page1.png"/>
<graphic xml:id="page2" url="page2.png"/>
<graphic xml:id="page3" url="page3.png"/>
<graphic xml:id="page4" url="page4.png"/>
</facsimile>
<!-- ... -->
<text>
<pb facs="#page1"/>
<!-- text contained on page 1 may be encoded here -->
<pb facs="#page2"/>
<!-- text contained on page 2 may be encoded here -->
</text>
</text>
```





Cette methode est tres generale

- <surface> definit une système de co-ordinés
- <zone> definit un zone d'interet
- des <graphic>s sont disponible a n'importe quel niveau





Bovelles-49r.png

De Geometrie.

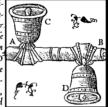
49

■DV SON ET ACCORD DES CLOCHES ET des alleures des cheuaulx, chariotz & charges, des fontaines: & encyclie du monde, & de la dimension du corps humain.

Chapitre septiesme.

1 Le son & accord des cloches pendans en vng mesme
axe, est faict en contraires parties.

Es doches ont quafi figures de rondes pyramides imperfactes & irregulieres: & leur accord fe fait par reigle geometrique. Com me fi les deux cloches C & D fom pendans i vng mefine axe ou efficu AB: ie dis que leur accord fe fera en cetraires parties, come voyez icy figuré. Car quad



lune fera en bault laultre declinera embas. Aultrement fi elles decli nent toutes deux enfemble en one mefme partie, elles feront difcord & fera leur fonnerie mal plaifante à oyr.

2. ¶Le vray accord de deux cloches par lattouchement des bataulx, est faict diametralement.



Hascune cloche a deux diuers costes, entre lesquels le batail touche par diuerses sois. Et à cause que



Encodage du fac-similé

```
<facsimile>
 <surface ulx="0" uly="0" lrx="200" lry="300">
   <zone xml:id="B49r" ulx="0" uly="0" lrx="200" lry="300">
     <qraphic url="Bovelles-49r.png"/>
   </zone>
   <zone ulx="105" ulv="76" lrx="175" lrv="160">
     <qraphic url="Bovelles49r-detail.png"/>
   </zone>
   <zone xml:id="B49rHead" ulx="25" ulv="25" lrx="180" lrv="60"/>
<!-- contains the title -->
   <zone xml:id="B49rPara2" ulx="28"</pre>
                                       uly="75" lrx="175" lry="178"/>
<!-- contains the paragraph in italics -->
   <zone xml:id="B49rFiq1" ulx="105" uly="76" lrx="175" lry="160"/>
<!-- contains the figure -->
   <zone xml:id="B49rW457" ulx="45" ulv="125" lrx="60" lrv="130"/>
<!-- contains the word "pendans" -->
 </surface>
</facsimile>
```

(Nota: on a proposé des identifiants pour chaque zone)





Encodage de la transcription

```
<pb facs="#B49r"/>
<fw>De Geometrie 49</fw>
<head facs="#B49rHead">DU SON ET ACCORD DES CLOCHES ET <lau>lb/> des alleures des chevaulx.
chariotz & charges, des fontaines:& <lb/> encyclie du monde,
& de la dimension du corps humain.</head>
<head>Chapitre septiesme</head>
<div n="1">
 Le son & accord des cloches pendans en ung mesme <lb/> axe, est
    faict en contraires parties.
 LEs cloches ont quasi fi<lb/>lb/>qures de rondes
    pyra<lb/>mides imperfaictes & <lb/> irregulieres: & leur
    accord se <lb/> fait par reigle geometrique. Com<lb/>me si les deux
    cloches C & D <lb/>
sont <w facs="#B49rW457">pendans</w> à ung
    mesme axe <lb/> ou essieu A B: ie dis que leur ac<lb/>cord se fera en
    co<ex>n</ex>traires parties<lb/> co<ex>m</ex>me voyez icy
    figuré. Car qua<ex>n</ex>d <lb/>lune sera en hault. laultre
    declinera embas. Aultrement si elles decli<lb/>le/>nent toutes deux
    ensembles en une mesme partie, elles seront discord, <lb/> & sera
    leur sonnerie mal plaisante à oyr.<fiqure facs="#B49rFiq1"/>
 </div>
```





Travaux pratiques

Monsiem, is vous ai escript vers la Si Marting, at smoie nostre arpenserie, er ensemble a Monsieur Loisel, pour vons faire entendre, que se famon flyne chose de bongie vous en feroie volemiers part. Je vous as ango eservet, gion and imprine quelas nouneaus glo Jeurs Alemans aneque Foqueling, sur Lerses delquely vons vons pources passer torstite livre de Mongran de la scala, na pas este se tost arrive, quon la entenér Monfieur de Candale, qui a Ffent est en Medone, a on nomeles de son livre, escript au page, touchans la reformation des Equinoc. et c. Le Cadinal Borromee lin a escript, que Clasins Jesmita, qui failt a Rome grand estate es profession des Margamanques. (ul a graph Glo Te The Enclides, escript de honolosijs plus que Frontius mi Monsterus, et fau commentaires for le petit laire de Defacrobosco, plus los minn tour sans pain). got ce bon stignens, fromwer at tge ADONIS we quely chose (is not fai que oudine. Car is noi ven bisolume ladine reconte recen de Rome)

ΓEI

Travaux pratiques

Enrichissez la transcription qui se trouve dans vinet.txt

- balisage des ratures avec
- balisage des abbréviations avec <choice>, <abbr>, <expan>, ou bien <am> et <ex>



