One Document Does it all: le système ODD

TEI@Oxford

novembre 2012

L'application d'un balisage 'intelligent'

La TEI s'applique à l'encodage des ...

- composants structuraux et fonctionnels d'un texte
- transcriptions diplomatiques des sources historiques, des images, des annotations
- lien, correspondances, alignements
- données et entités : par ex temps, personnes, lieux, événements
- annotations peritextuelles et metatextuelles (correction, suppression, ajouts)
- analyses linguistiques
- metadonnées de plusieurs types
- ... et des définitions formelles de schéma XML !

Cette intervention concerne le dernier point.

Pourquoi ODD?

- On a besoin d'un schéma XML pour définir ses ressources
- On désire fournir :
  - une documentation de la sémantique de son schéma XML
  - des notices des contraintes appliquées, des notes d'usage, des exemples
- Vous devez les maintenir en l'étape!
- Vous souhaitez partager cette documentation
  - avec d'autres personnes
  - avec vous-meme, à long terme
- Et vous préférez ne pas réinventer la roue...

ODD est né en 1991, à Bergen, en Norvège

Lido Cafe, Torgallemenningen 1a, Bergen

"A charming place with great location"

Reviewed 19 March 2012 via mobile

Nice food and lovely people there. The table cloth is replaced with two big sheets of blank paper and you can doodle whatever you like. The waitress was very patient and friendly. We all loved it!

Was this review helpful? Yes Problem with this review?

ODD n'était pas un nouveau concept

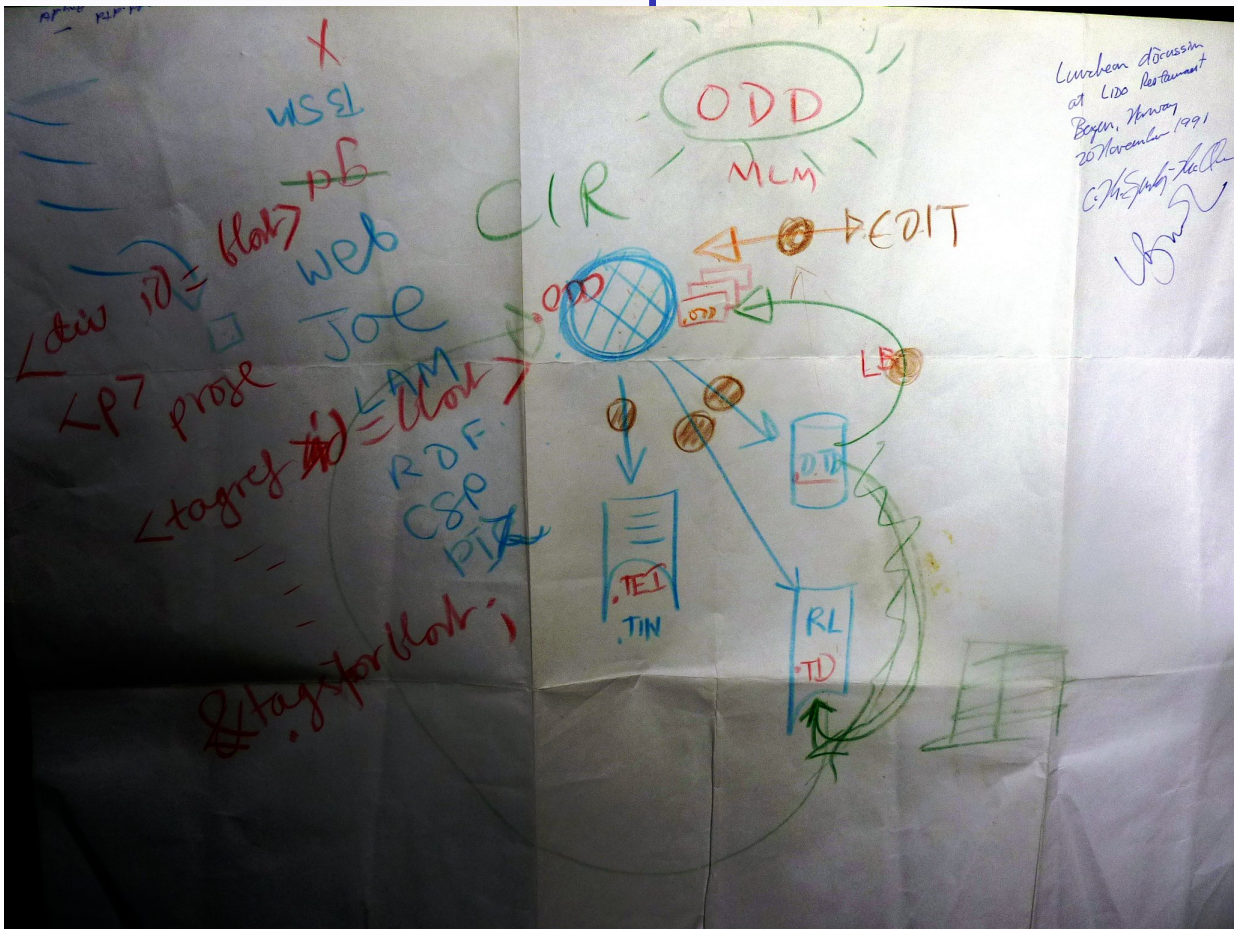

ODD : ça aurait pu être RDF...

- "literate programming" (Donald Knuth)
- java beans, doxygen...

L'idée essentielle (1)

Un vocabulaire spécialisé pour la définition

- des schémas
- des types d'élément XML, indépendant des schémas
- des regroupements de tels éléments, publics ou privés
- des patrons (MLE macros)
- des classes (et sous-classes) d'éléments

Pour la définition des références également, qui permettront de réunir dans un schéma

- des objets identifiables (dans la liste ci-dessus)
- des objets appartenant à d'autres espaces de nom

et qui serait intégrable à un système de balisage documentaire classique

L'idée essentielle (2)

Un processeur ODD :

- rassemble les composants référencés ou fournis
- résoud les incohérences ou duplications éventuelles
- peut contrôler ou valider les résultats
- émet un schéma exprimé en langue formelle (RELAXNG, DTD, WSD...)
- émet un document XML "pur" avec les composants documentaires

http://www.tei-c.org/Roma

Premier exemple simplissime

Nous avons besoin de <stuff>, qui contient un mélange des <bit>s et de <bob>s. Nous ne connaissons rien au sujet de la TEI, et n'en avons pas envie. Pareil pour les espaces de noms.

```
<schemaSpec ns="" start="stuff" ident="simpleS">
  <elementSpec ident="stuff">
    <desc>élément racine d'un schéma simplissime</desc>
    <content>
      <rng:oneOrMore>
        <rng:choice>
          <rng:ref name="bit"/>
          <rng:ref name="bob"/>
        </rng:choice>
      </rng:oneOrMore>
    </content>
  </elementSpec>
<!-- ... continue au prochain transparent -->
</schemaSpec>
```

exemple simplissime, contd.

```
<schemaSpec ns="" start="stuff" ident="simpleS">
<!-- ... contd -->
  <elementSpec ident="bob">
    <desc>élément pointeur du schéma simplissime</desc>
    <content>
      <rng:empty/>
    </content>
    <attList>
      <attDef ident="href">
        <desc>fournit l' URI de l'objet cible</desc>
        <datatype>
          <rng:data type="anyURI"/>
        </datatype>
      </attDef>
    </attList>
  </elementSpec>
  <elementSpec ident="bit">
    <desc>élément textuel du schéma simplissime (peut contenir des bobs) </desc>
    <content>
      <rng:zeroOrMore>
        <rng:choice>
          <rng:text/>
          <rng:ref name="bob"/>
        </rng:choice>
      </rng:zeroOrMore>
    </content>
  </elementSpec>
</schemaSpec>
```

So what?

- On peut maintenant générer un schéma RELAXNG, W3C, ou DTD par une transformation XSLT
- On peut extraire les fragments documentaires, notamment les descriptions des éléments et des attributs

TEI fournit un élément specialisé pour cela :

```
<specList>
  <specDesc  key="bit"/>
  <specDesc  key="bob"  atts="href"/>
</specList>
```

qui dans le document XML de sortie serait transformé en

```
<list  type="gloss">
  <label>
    <gi>bit</gi>
  </label>
  <item>élément textuel de schéma simplissime (peut contenir des bobs) </item>
  <label>
    <gi>bob</gi>
  </label>
  <item>élément pointeur du schéma simplissime</item>
</list>
```

Qu'est-ce qu'on pourrait souhaiter dire à propos des éléments?

- <desc>s ou <gloss> en plusieurs langues
- exemples d'usage
- contraintes additionelles (schématron)
- documentation des listes des valeurs closes
- association avec les classes TEI

Exemple de descriptions alternatives

```
<elementSpec module="core" ident="p">
<gloss>paragraph</gloss>
<gloss version="2007-12-20" xml:lang="kr">문단</gloss>
<gloss version="2007-05-02" xml:lang="zh-tw">□□</gloss>
<desc>marks paragraphs in prose.</desc>
<desc version="2007-12-20" xml:lang="kr">산문에서 문단을 표시한다.</desc>
<desc version="2007-05-02" xml:lang="zh-tw">□□□□□□□□</desc>
<desc version="2008-04-05" xml:lang="ja"> 散文の段落を示す。 </desc>
<desc version="2009-01-06" xml:lang="fr">marque les paragraphes dans un
texte en
prose.</desc>
<desc version="2007-05-04" xml:lang="es">marca párrafos en prosa.</desc>
<desc version="2007-01-21" xml:lang="it">indica i paragrafi in
prosa</desc>
<!-- ... -->
</elementSpec>
```

Exemples d'usage

L'élément <exemplum> contient un exemple de son usage et une note là-dessus...

```
<exemplum  xml:lang="en">
  <egXML><egXML><langUsage>
        <language  ident="en">English</language>
</langUsage>
</egXML>
  </egXML>
  <p>In the source of the TEI Guidelines, this élément declares itself and its content
     as belonging to the namespace <ident  type="ns">http://www.tei-c.org/ns/Examples</ident>.
This enables the content of the élément
     to be validated independently against the TEI scheme.</p>
</exemplum>
```

Définition du contenu d'un élément

- Actuellement, la TEI se sert du langage RELAXNG pour définir le contenu ("content model") des éléments et des attributs
- (mais on propose de modifier cela)

Les contraintes sont donc exprimables de plusieurs manières :

- par référence à un élément <valList>...
- par reference à un élément <datatype> (s'applique uniquement aux attributs)
- par inclusion des éléments <constraintSpec> (expression en ISO schématron)

OK, on revient à la roue

Effectivement, la TEI définit des éléments qui ressemblent beaucoup aux vôtres. Pourquoi ne pas s'en servir ?

```
<schemaSpec
   source="/usr/share/xml/tei/odd/Source/Guidelines/en/guidelines-en.xml"
   start="div"
   ident="simpleS-2">
  <elementRef  key="div"/>
  <elementRef  key="p"/>
  <elementRef  key="ptr"/>
</schemaSpec>
```

(L'attribut @source indique où trouver les définitions standardisées des éléments qu'on souhaite inclure)

Pourquoi se servir des définitions existantes ‡?

- Principe du moindre effort
- Vos ressources sont maintenant dotées d'une sémantique plus ou moins standardisée
- (Mais vos propres interprétations restent disponibles dans votre propre documentation)

Et rien n'empeche le "mix and match" :

```
<schemaSpec
   source="/usr/share/xml/tei/odd/Source/Guidelines/en/guidelines-en.xml"
   start="stuff"
   ident="simpleS-3">
  <elementSpec ns="" ident="stuff">
   <desc>élément racine d'un schéma simplissime</desc>
   <desc xml:lang="en">Root element for a very simple schema</desc>
   <content>
<!-- as before -->
   </content>
  </elementSpec>
  <elementRef key="p"/>
  <elementRef key="ptr"/>
</schemaSpec>
```

Dans le monde réel, les éléments se déplacent en groupes

Un module est une collection d'éléments nommés.. La TEI en fournit 22. Pour inclure l'une de ces collections, il suffit d'y faire référence avec l'élément <moduleRef> :

```
<schemaSpec start="TEI" ident="testschéma-4">
  <moduleRef key="core"/>
  <moduleRef key="header"/>
  <moduleRef key="textstructure"/>
</schemaSpec>
```

Tout élément TEI appartient à un seul module et possède un nom unique.

Recap

- La TEI propose plusieurs modules
- Chaque module propose plusieurs spécifications d'élément
- Chaque spécification contient
  - un nom canonique (<gi>)
  - (facultativement) des noms équivalents en plusieurs langues
  - une description de sa fonction (également disponible en plusieurs langues)
  - une indication des classes auxquelles il appartient
  - une definition pour chacun de ses attributs
  - une de son contenu (content model)
  - exemples d'usage ; notes
- une spécification schéma (<schemaSpec>) TEI contient
  - des références aux modules et/ou aux éléments
  - des (re)déclarations d'élément, classe, ou macro
- Un document TEI contenant une spécification de schéma s'appelle un ODD (One Document Does it all)

Liste des modules TEI

analysis	Simple analytic mechanisms
certainty	Certainty and uncertainty
core	éléments common to all TEI documents
corpus	Header extensions for corpus texts
declarefs	Feature system déclarations
dictionaries	Printed dictionaries
drama	Performance texts
figures	Tables, formulae, and figures
gaiji	Character and glyph documentation
header	The TEI Header
iso-fs	Feature structures
linking	Linking, segmentation and alignment
msdescription	Manuscript Description
namesdates	Names and dates
nets	Graphs, networks and trees
spoken	Transcribed Speech
tagdocs	Documentation of TEI modules
tei	déclarations for datatypes, classes, and macros available to all TEI modules
textcrit	Text criticism
textstructure	Default text structure
transcr	Transcription of primary sources
verse	Verse structures

Choisir sélectivement (1)

Vous pouvez spécifier les éléments que vous souhaitez supprimer parmi ceux qui sont proposés par un module:

```
<schemaSpec start="TEI" ident="testschéma-4a">
  <moduleRef key="core" except="mentioned quote said"/>
  <moduleRef key="header"/>
  <moduleRef key="textstructure"/>
</schemaSpec>
```

ou egalement :

```
<schemaSpec start="TEI" ident="testschéma-4b">
  <moduleRef key="core"/>
  <moduleRef key="header"/>
  <moduleRef key="textstructure"/>
  <elementSpec ident="mentioned" mode="delete"/>
  <elementSpec ident="quote" mode="delete"/>
  <elementSpec ident="said" mode="delete"/>
</schemaSpec>
```

(L'attribut @mode contrôle la résolution de déclarations multiples)

Choisir sélectivement (2)

Vous pouvez spécifier les éléments que vous souhaitez inclure parmi ceux qui sont proposés par un module:

```
<schemaSpec start="TEI" ident="testschéma-4b">
  <moduleRef key="core"/>
  <moduleRef key="header"/>
  <moduleRef key="textstructure" include="body div"/>
</schemaSpec>
```

ou également :

```
<schemaSpec start="TEI" ident="testschéma-4b">
  <moduleRef key="core"/>
  <moduleRef key="header"/>
  <elementRef key="div"/>
  <elementRef key="body"/>
</schemaSpec>
```

Unifications de déclarations multiples

Comme noté ci-dessus , l'attribut @mode sert à contrôler les actions d'un processeur ODD qui découvre plusieurs déclarations pour un seul composant.

valeur de @mode	à la première rencontre	à la rencontre suivante
add	ajouter une déclaration au schéma; traiter des enfants dans le mode add	signaler une erreur
replace	signaler une erreur	ajouter une déclaration; traiter de nouveaux enfants en mode replace; supprimer des enfants existants
change	signaler une erreur	traiter des enfants identifiables (i.e. portant un identifiant) selon leur mode; traiter des enfants non-identifiables en mode replace; retenir par defaut les enfants existants
delete	signaler une erreur	supprimer une déclaration existante, et ses enfants

éléments "identifiables"

Les éléments '*-spec' sont tous membres d'une classe att.identifiable qui fournit un attribut @ident équivalent à l'attribut global @xml:id; on s'en sert pour identifier la déclaration.

Pour faire référence à une telle déclaration, nous nous servons de l'attribut @key :

```
<elementRef key="bar"/>
<!-- implique l'existence ailleurs de ... -->
<elementSpec ident="bar">
<!-- .... -->
</elementSpec>
```

Similarly:

```
<moduleRef key="foo"/>
<!-- implique l'existence ailleurs de ... -->
<moduleSpec ident="foo"/>
```

Pour les attributs et les valeurs, <attDef> et <valItem> sont pareils.

Spécification des listes de valeurs

Les valeurs légales d'un attribut peuvent être specifiées par un <datatype> et/ou par <valList>.

Un besoin assez commun est de spécifier une énumération (une liste -- ouverte ou fermée -- des valeurs)

```
<attDef  ident="status">
  <desc>indique l'état courant du système selon un code de couleur</desc>
  <defaultVal>green</defaultVal>
  <valList  type="closed">
    <valItem  ident="red">
      <desc>fermeture complète du système</desc>
    </valItem>
    <valItem  ident="orange">
      <desc>fermeture imminente du système</desc>
    </valItem>
    <valItem  ident="green">
      <desc>état normal du système</desc>
    </valItem>
    <valItem  ident="white">
      <desc>état inconnu du système</desc>
    </valItem>
  </valList>
</attDef>
```

Datatypes

Servent à contraindre les valeurs légales d'un attribut :

```
<attDef ident="status">
  <datatype>
    <rng:ref name="data.enumerated"/>
  </datatype>
<!-- ... implique l'existence d'un vallist -->
</attDef>
<attDef ident="lastUpdated">
  <datatype>
    <rng:ref name="data.temporalExpr.w3c"/>
  </datatype>
</attDef>
```

Les datatypes définis par TEI sont, pour la plupart, mappés sur des définitions du W3C, en se servant d'un <macroSpec>

Spécification des patrons

L'élément <macroSpec> sert à associer un nom et une chaine de caractères. On s'en sert typiquement pour

- la définition de quelques modèles de contenu très répandus
- la définition des datatypes

```
<macroSpec  ident="macro.foo">
  <desc>a content model i plan to reuse often</desc>
  <content>
<!-- patron RELAXNG definissant la modele -->
  </content>
</macroSpec>
<macroSpec  ident="data.foo">
  <desc>a new datatype i just invented</desc>
  <content>
<!-- RELAXNG pattern defining the datatype -->
  </content>
</macroSpec>
```

Contraintes schématron

- Une spécification d'élément peut aussi contenir un élément <constraintSpec>, rassemblant des règles exprimées en ISO schématron

un cartoon doit inclure une graphie

Attention :

- le traitement de ces règles nécessite une étape additionnelle dans la validation des documents
- ces règles ne sont pas forcément traitables par toute langue de schéma

Le système de classe de la TEI : mode d'emploi

En définissant un nouvel élément on a besoin de considérer :

- son nom, sa description, etc.
- ses attributs
- son contenu
- son contexte

Le système de classe de la TEI facilite toutes ses considérations (sauf la première).

Les classes attributives ("Attribute Classes")

- Ces classes portent des noms commençant par att.; ex. att.naming, att.typed
- Chacune de ces classes contient un ensemble de déclarations d'attributs, qui sont heritées par les membres de la classe. Par ex, tous les membres de `att.naming` héritent des attributs @key et @ref; tous les membres de la classe `att.typed` héritent de @type et @subtype et ainsi de suite
- Pour qu'un élément porte l'attribut @type, donc, nous ajoutons cet élément à la classe `att.typed`.
- (Il reste possible de définir des attributs "locaux" avec l'élément indépendemment, bien sûr)

Les classes modélisantes (Model Classes)

- Ces classes portent des noms qui commencent en "model." et rassemblent des éléments dont la position dans l'arborescence est définie par un schéma. On peut définir cette position de deux manières :
  - si le nom de la classe contient le mot Like, par exemple model.biblLike, ses membres peuvent apparaitre dans le même contexte que l'élément indiqué (ici, <bibl>)
  - si le nom de la classe contient le mot Part, par exemple model.biblPart, ses membres peuvent apparaitre à l'interieur de l'élément indiqué
- En l'occurrence, les classes sont souvent sous-divisées. Par ex, model.pPart (les éléments qui peuvent apparaitre à l'interieur d'un <p>) comporte :
  - model.pPart.edit éléments représentants les interventions éditoriales par ex <corr>, <del> etc.
  - model.pPart.data'data-like' éléments par ex <name>, <num>, <date> etc.
  - model.pPart.msdesc des éléments de sous-paragraphe sont spécifiques aux descriptions des manuscrits par ex <seal> ou <origPlace>

Spécification des classes

- L'élément <classSpec> sert à déclarer une classe. Son attribut @type indique s'il s'agit d'une classe attributive (type="att") ou modelisante (type="model")
- Le <classSpec> pour une classe modelisante ne contient que sa description et son identifiant; celui d'une classe attributive contient aussi un <attList>

```
<classSpec  ident="model.foo"  type="model">
  <desc>classe contenant tous les éléments avec des noms idiots, inventés pour des raisons
     pedagogiques</desc>
</classSpec>
```

```
<classSpec  ident="att.foo"  type="atts">
  <desc>classe fournissant l'attribut <att>bar</att>
  </desc>
  <attList>
    <attDef  ident="bar">
<!-- ... -->
    </attDef>
  </attList>
</classSpec>
```

Sélection des classes

- Un élément indique les classes auxquelles il appartient en se servant d'un ou plusieurs éléments <memberOf>, regroupés dans un élément <classes> dans son <elementSpec>.
- Une classe indique les classes dont elle est sous-classe de la même manière.

```
<elementSpec  ident="bidule">
  <desc>élément nouveau inventé purement par motivation pédagogique</desc>
  <classes>
    <memberOf  key="model.foo"/>
    <memberOf  key="att.foo"/>
  </classes>
<!-- ... -->
</elementSpec>
```